

面向消费级 Ada 卡的 1.58-bit 三元 27B 大模型推理引擎移植

⚠️ 发布声明

本文档只发布 **工具与方法**（文档、打包器、验证脚本、引擎侧源码改动），**不包含、也不分发任何模型权重**，亦不含由权重派生的 `.ninfer` 制品。

模型 **Ternary Bonsai 2 27B**（底座 Qwen/Qwen3.8-27B）的权重版权归 **PrismML 及其上游（Qwen 体系）** 所有——**权重请前往官方作者处下载**，并遵守其许可条款。

本仓代码为 **Apache License 2.0**（不覆盖权重）；权重许可亦不覆盖代码。

技术报告 • 2026-09-20

摘要

三元（1.58-bit）量化把大模型权重压至信息论下限附近，却因格式与运行时生态缺位而长期停留在“能跑、跑不快”。本文报告一次完整移植：把 **Ternary Bonsai 2 27B**（三值权重 + Hadamard 折叠基）接进自研单卡推理引擎 **NInfer**，在消费级 **RTX 4080 SUPER (sm_89, 32 GB, Windows)** 上跑通并达标。工作涵盖：Ada 线自建引擎、三元格式注册与逐字节无损打包器、运行时折叠基变换（置换→符号→Hadamard）及逆向、fused 家族全接线、decode 与批量两条快路径（SIMT GEMV / 张量核 `mma.m16n8k16`），以及将同族 NextN 层按引擎规格拼装为 MTP 草稿头。

结果：纯解码 **62–64 t/s**（等效带宽 447 GB/s），MTP K=2 单流峰值 **130.8 t/s**（4/5 真实负载 ≥ 101 ），预填充 **356–439 tok/s**（原 53.9–55.7）；制品 **7.74 GB**；**PPL 6.445**（黄金参照 6.8196 ± 0.5365 ）；20 题社区基准 **19/20 = 95%**，与同引擎全精度 27B 持平且错题相同 [9]。

关键词：三元量化；Hadamard 旋转基；推理引擎；张量核；投机解码；CUDA；sm_89

1 引言

1.1 动机

27B 级模型全精度权重约 18.2 GB，叠加 KV 缓存后单张 32 GB 消费卡难以容纳。三元量化 ($w \in \{-1, 0, +1\}$) 把每权重压至 $\log_2 3 \approx 1.585$ bit，并通过基旋转维持表达力，是“既小又快”的少见候选。但其落地卡在两处：**格式缺位**（各引擎按自有内存布局组织码字/高平面/块级 scale，不可直接复用）；**运行时缺位**（权重存于旋转基，激活须施加匹配变换，否则形状类型尺寸全对而输出错乱，且不报错）。

1.2 问题定义

#	障碍	表现
A	引擎不支持目标卡	上游构建脚本面向 sm_120a ； 本项目硬件为 sm_89
B	引擎不认识该权重	全树无 GGUF 读取器，亦无旋转基语义
C	官方路径无投机生态	三元模型仅能跑 llama.cpp 线，缺草稿头/前缀复用/高效验证

1.3 贡献

- 1. 在消费级 Ada / Windows 上**首次公开跑通端到端**（截至 2026-09，公开可核范围内无第二家落地产物；存在 WIP 工程但未产出可运行制品）[4,13]；
- 2. **无损打包器**：自写 GGUF 解析与三元解码，402 个三元矩阵逐字节搬运（不反量化再量化），按引擎 row-split 布局装配 [1,10]；
- 3. **折叠基变换的运行时实现**：将置换→符号→Hadamard 折进内核，并厘清其逆向仅作用于词嵌入查表 [1,6]；
- 4. **两条快路径**：decode 用 warp-per-row GEMV（零 __syncthreads ），批量用 mma.m16n8k16，将 MTP 验证轮由负收益翻正 [1,17]；
- 5. **MTP 头拼装**（必要工程手段，非差异化）：借用同族 NextN 层，取得 K=2 下 59.4% 接受率、2.19 tok/轮 [1,7]；
- 6. **验证方法学**：以"能证伪什么"为准绳设计判据，用负控、跨实现互验、行级指纹多重集、T>1 引擎侧验证与 PPL 口径，捕获两处"常规校验全绿"的致命缺陷 [2,3]。

2 背景

2.1 三元权重编码

$w \in \{-1,0,+1\}$ 以 128 权重为组编码，两种格式并用 [1]：

格式	码字	高平面	scale	合计
PTQ1_0_G128	24 B	2 B	2 B (fp16)	28 B/组
PQ2_0_G128	32 B	0	2 B (fp16)	34 B/组

PQ2_0 解码（与 ggml-quants.c 逐字对齐 [15]）：

```
code = (qs[j >> 2] >> (2 * (j & 3))) & 0x3      // j: 组内序号 0..127
w     = (code - 1) * d                             // d: 该组 fp16 scale
```

块级 scale 带输出行下标，故"每行每 128 个乘一次"即为层内理论极限（已达成）。

2.2 折叠基变换

运行时必须对激活施加与权重端匹配的变换 [1,6]:

正向（权重侧）： $y = W' \cdot (H \cdot (s \odot (P \cdot x)))$

// 顺序 $P \rightarrow s \rightarrow H$

逆向（仅词嵌入）： $h = s \odot (H \cdot z)$

// 顺序 $H \rightarrow s$

- **H**: 归一化 Sylvester–Walsh–Hadamard, 块宽 1024, $H[i][j] = (\text{popcount}(i \& j) \& 1) ? -1 : +1$, 再乘 $1/\sqrt{1024}$; H 对称正交。
- **s**: 每输入宽度一份的 ± 1 向量, `sign_widths = [5120, 6144, 17408]` (Σ 28672)。
- **P**: 仅作用于 `.ssm_out.` (`gdn/output`, $K = 6144$)。因打包器已将 GDN 张量统一为 grouped 形式, **ninfer 侧不再施加 P** (二次置换即为错) [1,2]。

2.3 制品与布局契约

引擎消费单一 `.ninfer` 制品, 文本权重按 **row-split 三平面** (low/high/scale) 存放, 另有 globals、MTP 与视觉载荷; 本项目产物 8,306,927,628 B (文本 6.696 GiB)、1126 个对象 [1]。引擎 Tensor 与 ggml 同源, `ne[0]` 为连续轴: 激活 `x[k,t]` 位于偏移 `t·K + k`。**T = 1 时 token 主序与行主序完全重合**, 为本文首要陷阱 [1,2]。

3 系统设计

3.1 三条链路

GGUF 源 —[L1 打包]—> .ninfer —[L2 加载]—> 引擎内存 —[L3 运行]—> 服务/基准

L1 判据为尺寸反验 + 行级多重集 + 装配规则全绿; L2 要求每个对象均被 Binder 消费 (否则整包拒载) [2]; L3 旋转一次喂多个权重, decode 与批量分流。

3.2 设计原则

1. **零精度损失优先**: 码字逐字节搬运, 不反量化再量化 (否则体积涨回十余 GB, 三元失去意义) [1,4];
2. **旋转由 qtype 纯驱动**: 401 个折叠权重 + 1 个逆向权重 (`token_embd`) = 402, 恰等于三元张量总数, 无需模型层逐处挂 hook [2];
3. **判据先行**: 先定义"正确应看到什么、错误会看到什么", 再实现 [2]。

3.3 逐张量映射（节选，权威规格见 [10]）

制品对象	形状 (N,K)	来源与规则
text/token_embedding	(248320, 5120)	原样；运行时查表后施加逆向变换
text/output_head	(248320, 5120)	原样（正向）
.../gdn/query_key	(4096, 5120)	attn_qkv 行 [0:4096]
.../gdn/value_z	(12288, 5120)	attn_qkv[4096:10240] + attn_gate[0:6144]，各自按头粒度重排
.../gdn/output	(5120, 6144)	ssm_out 原样（不施加 P）
.../mlp/gate_up	(34816, 5120)	concat(ffn_gate, ffn_up) 沿行
.../attention/query_key	(7168, 5120)	attn_q 偶数 256 行块 + attn_k
.../attention/gate_value	(7168, 5120)	attn_q 奇数 256 行块 + attn_v
text/hadamard_signs	FP32[28672]	prism.hadamard.sign_values

层类型判据：存在 blk.{1}.attn_q.weight 即为全注意力层（64 层中 16 全注意力、48 GDN）[1]。

4 实现

4.1 M0 引擎适配

自建支持 Ada 的源码线（sm_89 + MSVC + CUDA 13.3 旁装 + Ninja + Windows）。首要构建坑为 **MSVC 头文件依赖扫描失效**：改 .h 后构建工具报"没活干"，改动静默不生效，最终因跨编译单元结构体尺寸不一致而运行期崩在栈保护（0xc0000409）。对策是改 .h 后 touch 所有包含它的 .cpp [1,2]。

4.2 M1 格式注册

新增 PQ2_0_G128 / PTQ1_0_G128 两个 QType 与解码 atom，以独立参考解码器逐 bit 比对（0/30720 失配），并令两种打包互证（max|diff| = 0.0）[1,2]。

4.3 M2 旋转内核

自包含 device 内核：D1024 归一化 SWHT（蝶形约定与树内 hadamard_d256.cuh 一致，5 级 lane shuffle + 5 级寄存器 span + 收尾 $\times 2^{-5}$ ）、显式符号、P 置换；正向与逆向（就地）双入口。置换折进 load 而不落中间量 [1]。

4.4 M3 家族接线

家族	接法
gdn_input_proj	旋转一次 → 3 个 GEMM (plain / conv-snapshot / conv-record)
attn_input_proj	旋转一次 → 4 个 GEMM
linear_swiglu	融合 gate_up GEMM + 现成 silu_mul (按行切半)
linear_add	GEMM 到 scoped scratch + residual_add
embedding	查表后就地施加逆向变换
LM head	折叠后的 output_head 需带工作区 (旋转 scratch)

[1]

4.5 打包器

自写 GGUF 解析 (引擎无 GGUF 读取器) , 逐张量按 [10] 装配。两处"尺寸守恒的置换错误":

- 1. **块内去交错**: GGUF 块为 {fp16 d; qs[32]} (scale 在前) , ninfer 为三平面, 必须按平面去交错, 否则尺寸全对而数据错 [1];
- 2. **头粒度置换**: 行轴为"48 头 × 每头 128 行"时, 置换须按头粒度施加 (src = perm48(row//128)*128 + (row%128)) ; 对行号直接施加头级置换非双射, 同时造成重复与丢失 [1,2]。

4.6 decode 快路径 (T = 1)

— warp 一行: PQ2_0 打包使 lane 1 的 4 列落在同一字节, 故每组每 warp 只读 1 B 码字 + 2 B scale, 5 级 shuffle 归约, 零 __syncthreads ; 含 scale 单次 16-bit 读、激活成对 bf16 读、scale 乘法提到 4 个 FMA 之外等微优化。实测每 warp 处理 2 行反而更慢 (32.8 vs 46.4) ——多出累加器吃寄存器、常驻 warp 数下降, GEMV 依赖 occupancy [1]。

4.7 批量快路径 (T ≥ 2)

动机: decode 受 DRAM 带宽约束, 每 token 需读约 7.14 GB 权重; 若验证轮 (T = 3) 仍用 SIMT, 则每权重每 token 各付一条 FMA, 搬运字节相同而耗时达 T = 1 的 2.29× (等效带宽 483 → 211 GiB/s) , 这正是 --draft-tokens 2 仅 51.0 t/s (负收益) 的根因 [1]。

内核 (ternary_rowsplit_mma_small_t) [1,17]:

要素	取值
基本块	<code>mma.m16n8k16</code> ：16 行 × 8 token × 16 k, tile 内 token 共用一次权重读取
解包	256 项 shared LUT：1 字节 → 4 个三值权重，一条 <code>LDS.64</code>
搬运	<code>cp.async</code> 双缓冲（2 stages）
分块	4 warp/CTA、64 行/CTA、K chunk 512
token 环	按 8-token 走完序列，同一 kernel 覆盖 verify（T=2..8）与 prefill（T>8）
资源	静态 shared 38144 B、76 寄存器

两项决定性调参：

- **CTA 数**：8 warp/CTA 时窄投影仅发出 40 个 CTA（80 SM 空一半）；改 4 warp/CTA 后轮耗时 29.4 → 25.2 ms，但 lm head（248320×5120）出现回归，需单独处理。
- **K 分块 256 → 512**：每 chunk 有 2 次 `__syncthreads` 且每 CTA 每 chunk 重搬一次 activation，分块加倍使二者各减半；代价为 shared 21.2 → 38.1 KB、occupancy 降至 2 CTA/SM，但更快——`cp.async` 流水比 occupancy 更关键。

4.8 MTP 头拼装

三元模型自身不带 MTP 头，裸解码止步 62 t/s。将同族 Qwen3.8-27B 的 NextN 单层按引擎 `mtp/*` 12 张量规格拼入制品 [1,7]：前提是该块不做 Hadamard 旋转（残差流处于原始基）；重建头与原头 **12/12 余弦 ≥ 0.99966、7 个 norm 逐字节相同**；实测 K=2 接受率 59.4%（任务敏感：英文代码 40.8% → 中文短答 80%）、2.19 tok/轮；窗口 **N = 2 最优**，N ≥ 3 接受率降至 40.9 / 33.2 / 22.9%，本线 N ≥ 6 不支持。

5 验证方法学

5.1 三条原则

1. **每条判据须写明能证伪什么**——用错判据比不验更危险，会得到"自治的假绿"；
2. **负控必须存在**；对照组全零往往是方法失效信号，而非结论；
3. **须有独立于被验路径的旁证**——"搬运无损"类判据对偏移错误完全盲（读错的字节原样进、原样出）[2]。

5.2 四级验证

级别	判据	能证伪
装配	<code>check_assembly.py</code> 15/15 规则逐行成立	行置换 / 重复 / 丢失
解码	与独立参考实现逐 bit 相同；两种打包互证	单一实现的系统性误读
变换	numpy 显式矩阵 oracle 6/6 (rel_l2 2.2e-03) + 6 类负控全分离	符号顺序 / 未归一化 / 符号行错位 / 漏 P / P 反向
布局	T > 1 用例 + 引擎侧注入式 dump	步长 / 布局类错误 (T = 1 全绿亦测不出)

[1,2,3]

布局一项的教训：头号缺陷表现为 `T=1 cos +0.999997` 而 `T=55 cos +0.006`。**必须至少有一个 T > 1 用例且在引擎侧验证**——独立 harness 只能证明"公式自治"，其布局是自身假设 [2,3]。

5.3 端到端口径

- 数值正确性用 **PPL**：正确为个位数至十几，错误为几百 (`1,128,420` → `6.43557`) [2];
- `decode` 改动加**贪心输出逐字比对** (PPL 走 `prefill`，测不到 `T = 1`) [1];
- 定位主因看**"修好一个真 bug 后数字动了多少"**：修 `gdn_value_z` 后 PPL 仅降 4.7%，据此判定主因在更前端 (`embedding`) [2]。

5.4 测量学陷阱

- **micro-benchmark 不 flush L2 会高估带宽；flush 过头会报出超物理上限的数** (实测 `1384 GiB/s` > 本卡 `736 GB/s`) ——绝对值以引擎自报为准 [2,17];
 - **内核"少干一半活"会伪装成提速**：K 分块改动时搬运循环仍按旧宽度写死，基准报"快 1.43×"，实为少搬一半数据，由正确性检查报 `NaN` 暴露 [2];
 - **launch 失败伪装成"快得离谱 + 全零"**：不在 `launch` 后查 `cudaGetLastError()` 即会误读为"`0.002 ms` 跑完 `322 MB`" [2];
 - **idle 时钟使短基准失真** (同一二进制两次 `0.60 / 0.82 ms`) [2];
 - **报数须附任务与长度** (`tok/轮` `1.82–2.38`；接受率随长度 `66.7% → 54.8%`) [2]。
-

6 实验

6.1 设置

RTX 4080 SUPER (AD103, sm_89, 32,760 MiB, 折算带宽 **736 GB/s** [1,2,17]) ; Windows + MSVC 14.51 + CUDA 13.3 + Ninja; 对比时全部模型使用**同一引擎二进制**, 唯一变量为权重; 20 题题库取自公开数据集 (MMLU / MMLU-Pro / ZebraLogic / AIME 2024 / HumanEval, 6 个难度层) [8,9]。

6.2 速度

指标	结果
纯解码 (T = 1)	62–64 t/s , 等效带宽 447 GB/s (llama.cpp 同卡 356 GB/s) [1]
单流 + MTP K=2	96.7 – 130.8 t/s (4/5 真实负载 ≥ 101) [1]
预填充	356–439 tok/s (原 53.9–55.7) [1]
同卡官方路径 (llama.cpp 裸跑 59.9)	130.8 t/s $\approx$ 2.2$\times$ (我方含投机, 对方为裸跑) [1,4]
llama.cpp @ RTX 5090 (裸跑 129.9)	130.8 t/s, 同级 (同上口径差异) [1,4]

MTP K=2 轮耗时 43.5 ms $\rightarrow$ 约 20 ms, 单流吞吐由 51.0 (负收益) 升至 96.7–130.8 [1]。

6.3 体积

	体积
全精度 27B 权重	18.2 GB
本制品	7.74 GB (文本 6.696 GiB)
官方 PTQ1_0 打包	5.9 GB

即 **2.4 $\times$ 更小** [1]。

6.4 智能水平

同一 xhigh 档、同引擎、同参数, 唯一变量为权重 [9]:

模型	思考档	基准得分	墙钟	唯一错题
★ 三元 Bonsai 27B	xhigh	19/20 = 95%	392 s	qid 4 · MMLU-Pro:law
千问 27B (全精度)	xhigh	19/20 = 95%	764 s	qid 4 · MMLU-Pro:law
ornith 1.5 35B-A3B (MoE)	default	18/20 = 90%	209 s	qid 4 / qid 8 [8]

三元与全精度 **打平且错题相同** (MMLU-Pro:law, 三个模型均答 G), 属知识缺口而非算力问题 [8]。同档墙钟 392 s vs 764 s, **1.95 $\times$** [9]。PPL **6.445** (黄金参照 6.8196 ± 0.5365) [1]。

6.5 消融与对照

- **张量核开关**（同窗口 PPL A/B）：`NINFER_TERNARY_MMA=1` 得 121.1577, `=0` 得 121.1183, **相差 0.033%**, 同条件快 5.8–7.2× [2];
- **K 分块 256 → 512**: 说明文 90.0 → 109.9 t/s、中文短剧 74.9 → 91.0 t/s, tok/轮不变 [1];
- **覆盖率**: 322/322 三元对象可走张量核, 0 回退 [1];
- **独立 harness**: 按真实 shape 分布扫描 T (含 L2 flush) , `rel_l2` 1e-05 – 4e-05 [1];
- **非三元回归对照**: 输出通顺, decode 35.5 t/s、prefill 436.9 t/s [1]。

6.6 思考档消融（兼释早期口径）

同引擎、同题库，仅改思考档 [9]:

模型	low	medium	xhigh
三元 Bonsai 27B	16/20 (80%)	16/20 (80%)	19/20 (95%)
千问 27B (全精度)	18/20 (90%)	17/20 (85%)	19/20 (95%)
ornith 1.5 35B-A3B	—	—	18/20 (90%) [<code>default</code> 档]

- 三元由 low 档 16/20 升至 xhigh 档 19/20, **增量 3 题**分布在 L2 中等、L4 逻辑·大格、L5 极难各 +1;
- 全精度在 low 档反而最高 (18/20) 、medium 回落 (17/20) : **档位不是单调变量**, 跨档比较无意义;
- low 档两模型均会烧穿 16,384 token 上限 (各有 1–2 题 `finish=length`、正文 0 字符) ; xhigh 档三元不再触顶, 单题最长思考 8.6k tok vs 全精度 14.3k tok;
- 故**早期发布中的 16/20 是 low 档成绩**, 与本文 19/20 (xhigh) 不矛盾 —— **对外报数必须同时给出思考档**;
- 判分器历史: 修复前 (HumanEval 判分缺前导 import) 三元 low 档为 14/20, 修复后 16/20 [8]。

7 讨论

7.1 关键设计决策

零精度损失的打包是三元的体积优势前提; **旋转由 qtype 纯驱动**把接线收敛到"正向 1 处 + 逆向 1 处"; **快路径按 T 分流**使同一 kernel 同时覆盖 verify 与 prefill [1,2]。

7.2 局限

- **投机窗口窄**: 草稿头仅 1 个 NextN 层, $N \geq 3$ 接受率骤降, 2.19 tok/轮基本封顶 [1];
- **带宽利用 ~61%**: 447 GB/s vs 物理 736 GB/s [1,4];
- **体积未达下限**: 当前 2.125 bit/权重, 尚有约 12% 空间 (下限 1.585) [4];
- **引擎能力边界**: 该 fork 不支持图片输入; `sm_89` 不可用 `k8v4` KV; 单卡不可跨模型并行 [2]。

7.3 未来方向

1. **数学层**：表示层走向 base-3 (1.875) 乃至下限 (1.585)；三值**不需要乘法** ($\{-1, 0, +1\}$ 等价于取反/跳过/恒等，每权重约 2 条指令 vs 当前约 5 条)；代数上可整体消去 -1 项 (该和项与输出行无关、每块只算一次)，预估一轮省约 5% [4]；
 2. **引擎层**：T = 1 亦接张量核 (引擎自报 +17%)；多路并发合并进 $\text{batch} \geq 8$ 的 tile (实测 5 路仅 25% 效率，属调度层问题，不动数学)；布局按三元重排 / 全融合 [4,5]；
 3. **MTP 层**：改用或重训更强草稿头 (引擎已注册 DFlash2 等替代投机路；按上游 DSpark 配方重训，官方一代在 L40S 上可达 1.8–2.4 $\times$) [4,7]；
 4. **共同验收口径**：达到带宽率 (权重 $\div$ 轮时间 $\div$ 物理带宽)、20 题得分不掉、PPL 落在黄金参照带内 [4]。
-

8 结论

将 1.58-bit 三元 27B 完整接进自研引擎并在单张消费级 32 GB Ada 卡上跑通：体积 7.74 GB (较全精度小 2.4 $\times$)；纯解码 62–64 t/s，MTP K=2 单流峰值 130.8 t/s；预填充提升约 8 倍；20 题基准 19/20，与同引擎全精度 27B 打平且错题相同。

让模型“能跑”不难；让它“跑对、还跑得快”，难点全在细节——每一处字节、每一处步长、每一次同步都须正确，而这依赖一套以“能证伪什么”为准绳的验证方法学 [2,3]。

本项目的发布物为**工具与方法** (文档、打包器、验证脚本、引擎侧源码改动)，**不含任何模型权重**；权重请前往官方作者处获取并遵守其许可 [13,14]。

附录 A 复现清单

#	步骤	判据（不满足即停）
0	环境自检	sm_89 可用；工具链版本正确
1	权重哈希	与官方发布一致
2	读 GGUF 元数据	block_size=1024、 $\sum$ sign_widths=28672、weight_names=401、inverse=[token_embd]、gdn_v_grouped=true
3	打包	产物尺寸精确匹配；对象数一致
4	验制品（4 脚本）	全绿（尤其装配 15/15）
5	改引擎源码	按改动清单落地；改 .h 后 touch 相关 .cpp
6	构建	BUILD OK，并确认改动确实重编
7	装快路径	decode $\geq$ 60 t/s；T $\geq$ 2 走张量核
8	端到端正确性	输出通顺；PPL $\approx$ 6.4–6.8（错则几百）
9	速度	T = 1 与 T $\geq$ 2 分别实测并算等效带宽
10	基准	答案键审计；得分与困惑度
11	收工	显存回落至基线；无残留进程

[1]

附录 B 发布与许可

发布内容为技术文档、打包器与验证工具、引擎侧源码改动（补丁），代码以 **Apache License 2.0** 发布；**不发布任何模型权重及由权重派生的 .ninfer 制品**。Ternary Bonsai 2 27B（底座 Qwen/Qwen3.8-27B）权重版权归 PrismML 及其上游所有，请前往官方渠道获取并遵守其许可 [13,14,18]。

参考文献

项目内文档与数据

[1] 《Bonsai 三元移植复现手册》，2026-09-19。E:\infer-docs\01-复现手册\Bonsai-三元移植-复现手册-20260919.md [2] 《链路 & 坑·总表》，2026-09-19。E:\infer-docs\05-链路 & 坑\坑与链路总表.md [3] 《Bonsai 三元首跑·根因与修复》，2026-09-19。E:\infer-docs\06-实测与结果\ [4] 《三元：数学边界与引擎优化清单（暂存·待验证）》，2026-09-20。E:\infer-docs\03-规格与设计\三元-数学边界与引擎优化-暂存-20260920.md [5] 《六路工位设计与异构调度方案》，2026-09-20。E:\infer-docs\03-规格与设

计\六路工位设计与异构调度-20260920.md [6] 《Bonsai 2 27B 技术规格》，2026-09-18。E:\infer-docs\03-规格与设计\Bonsai2-27B-技术规格-20260918.md [7] 《Bonsai 投机路线图》，2026-09-19。E:\infer-docs\03-规格与设计\Bonsai-投机路线图-20260919.md [8] 《同台竞技·20 题社区题库》，2026-09-19。E:\infer-build\report.md [9] 评测原始数据 (xhigh 档，每模型 20 题逐题记录)：E:\infer-build\res-ternary-xhigh.json、res-qwen27b-xhigh.json、res-ornith15-35b-a3b.json [10] 打包器权威映射规格。E:\视频_bonsai\ternary-pack\MAPPING.json [11] 《总索引》，2026-09-19。E:\infer-docs\00-总索引\INDEX.md [17] 《Bonsai 三元 mma 快路径·交接》，2026-09-19。E:\infer-docs\02-交接与状态\ [18] 发布仓：<https://modelscope.cn/models/shensanshu/ninfer-ada-ternary> (Apache-2.0; 不含权重)

外部来源

[12] NInfer —— 上游单卡推理引擎 (Apache-2.0) 。<https://github.com/Neroued/ninfer> [13] PrismML, *Bonsai 2 27B* 模型发布与权重页。<https://prismml.com/news/bonsai-2-27b> [14] Qwen, *Qwen3.8-27B* 底座模型与其许可条款。<https://huggingface.co/Qwen> [15] llama.cpp 生态量化实现 ggml-quants.c (三元编解码语义对齐对象)。<https://github.com/ggml-org/llama.cpp> [16] HadaCore / TurboQuant —— 张量核上 FWT 的设计思路来源 (方法参考，本文为独立实现)

本文数字均取自引擎自报 *timings* 与 *PPL* 实测，并附原始评测 *JSON* [9]；不同硬件、驱动、*CUDA* 与内存带宽下会有差异。